

## **Révision du Module : Machine Learning**

**Lisez attentivement chaque question et répondez-y de manière précise dans la feuille de réponse fournie.**

**1. Quelle est la principale raison d'effectuer une normalisation des données ?**

- a) Réduire le nombre de variables
- b) Assurer une meilleure convergence des algorithmes d'apprentissage
- c) Supprimer les valeurs aberrantes
- d) Augmenter la dimensionnalité

**2. La différence entre standardisation et normalisation est :**

- a) La standardisation transforme les données en une distribution normale
- b) La normalisation centre les données autour de 0
- c) La standardisation met toutes les valeurs entre 0 et 1
- d) La normalisation convertit les valeurs en scores Z

**3. Pourquoi applique-t-on un scaling Min-Max ?**

- a) Pour augmenter la variance du modèle
- b) Pour centrer les données autour de leur moyenne
- c) Pour transformer les données dans l'intervalle [0, 1]
- d) Pour supprimer les outliers

**4. Quel algorithme est le plus sensible aux valeurs aberrantes ?**

- a) K-Means
- b) Régression linéaire
- c) Random Forest
- d) SVM

**5. Quelle technique est utilisée pour gérer les valeurs manquantes dans un dataset ?**

- a) Encodage one-hot
- b) Imputation par la moyenne ou la médiane
- c) Réduction de dimension
- d) Transformation logarithmique

**6. Quelle méthode d'imputation est appropriée pour les données continues ?**

- a) Mode
- b) Moyenne
- c) Médiane
- d) Label Encoding

**7. Lorsque les données sont asymétriques, quelle méthode d'imputation est préférable ?**

- a) Moyenne
- b) Médiane

- c) Mode
- d) Constante arbitraire

**8. Quelle est la différence entre imputation par la moyenne et par interpolation ?**

- a) Interpolation utilise toujours la moyenne
- b) Interpolation prend en compte la relation temporelle ou spatiale
- c) Imputation par la moyenne est plus rapide
- d) Il n'y a pas de différence

**9. L'encodage one-hot est particulièrement utile pour :**

- a) Les variables numériques
- b) Les variables catégorielles nominales
- c) Les séries temporelles
- d) Les variables continues

**10. Le label encoding est problématique pour quel type de variable ?**

- a) Variables numériques
- b) Variables catégorielles nominales
- c) Variables booléennes
- d) Séries temporelles

**11. Quelle est la principale différence entre label encoding et one-hot encoding ?**

- a) Label encoding crée une nouvelle colonne pour chaque catégorie
- b) One-hot encoding évite l'ordre implicite
- c) Label encoding est utilisé pour les variables continues
- d) One-hot encoding est moins performant

**12. Quelle méthode de détection des valeurs aberrantes repose sur la densité des points ?**

- a) Z-Score
- b) DBSCAN
- c) Isolation Forest
- d) Boxplot

**13. Quelle transformation peut être utilisée pour traiter des outliers extrêmes ?**

- a) Suppression directe
- b) Transformation logarithmique
- c) Scaling Min-Max
- d) Standardisation

**14. Quelle est la principale limite de la méthode Z-Score pour détecter les outliers ?**

- a) Elle suppose une distribution normale
- b) Elle est trop rapide
- c) Elle ne fonctionne qu'avec des données discrètes
- d) Elle ne détecte pas les valeurs manquantes

**15. Quelle technique permet de réduire la dimensionnalité tout en conservant un maximum de variance ?**

- a) PCA (Principal Component Analysis)

- b) K-Means
- c) Label Propagation
- d) Gradient Boosting

**16. Quelle est la principale différence entre PCA et LDA ?**

- a) PCA est supervisé, LDA non supervisé
- b) PCA maximise la variance, LDA maximise la séparation des classes
- c) LDA est utilisé uniquement pour la régression
- d) PCA et LDA sont identiques

**17. Quel problème peut être causé par une trop forte réduction de dimension ?**

- a) Augmentation du bruit
- b) Perte importante d'information
- c) Meilleure classification
- d) Augmentation de la variance du modèle

**18. Quelle est la principale raison d'utiliser t-SNE au lieu de PCA ?**

- a) t-SNE est plus rapide
- b) t-SNE est adapté pour la visualisation en haute dimension
- c) t-SNE conserve mieux la variance globale
- d) t-SNE ne nécessite pas de normalisation

**19. Quel est l'objectif principal de l'imputation des valeurs manquantes ?**

- a) Éviter l'échantillonnage aléatoire
- b) Maintenir l'intégrité du modèle
- c) Augmenter le nombre de données disponibles
- d) Réduire la dimensionnalité

**20. Quelle métrique est affectée par des variables fortement corrélées ?**

- a) Accuracy
- b)  $R^2$  (Coefficient de détermination)
- c) Silhouette Score
- d) Davies-Bouldin Index

**21. Quel est le principal objectif de l'apprentissage supervisé ?**

- a) Trouver des structures cachées dans les données
- b) Prédire une sortie à partir d'une entrée en se basant sur des exemples étiquetés
- c) Réduire la dimensionnalité des données
- d) Optimiser le clustering des données

**22. Quelle est la principale différence entre régression et classification ?**

- a) La régression prédit une valeur continue, la classification une catégorie
- b) La classification est toujours plus précise que la régression
- c) La régression ne nécessite pas d'apprentissage supervisé
- d) La classification ne fonctionne qu'avec des variables catégorielles

**23. Quel algorithme est couramment utilisé pour un problème de classification non linéaire ?**

- a) Régression linéaire

- b) K-Nearest Neighbors (KNN)
- c) Régression logistique
- d) PCA

**24. Dans un arbre de décision, quel critère est souvent utilisé pour choisir le meilleur attribut ?**

- a) Coefficient de corrélation
- b) Gain d'information ou entropie
- c) Distance Euclidienne
- d) Coefficient de Gini

**25. Quel est l'algorithme le plus adapté pour prédire le prix d'une maison ?**

- a) Régression logistique
- b) Régression linéaire
- c) K-Means
- d) SVM

**26. Quelle méthode est utilisée pour évaluer la performance d'un modèle de classification ?**

- a) Matrice de confusion
- b) Silhouette Score
- c) Variance expliquée
- d)  $R^2$

**27. Quelle métrique est la plus adaptée pour un problème de classification déséquilibré ?**

- a) Accuracy
- b) F1-score
- c)  $R^2$
- d) Erreur quadratique moyenne

**28. Quel est l'impact d'un coefficient de détermination ( $R^2$ ) proche de 1 dans un modèle de régression ?**

- a) Le modèle a une faible capacité prédictive
- b) Le modèle est surajusté
- c) Le modèle explique bien la variance des données
- d) Le modèle sous-ajuste les données

**29. Quel avantage offre un modèle de Random Forest par rapport à un arbre de décision unique ?**

- a) Il est plus rapide à entraîner
- b) Il est moins sujet au surajustement
- c) Il fonctionne uniquement pour la classification
- d) Il réduit la dimensionnalité des données

**30. Comment le modèle Random Forest réduit-il le risque de surajustement ?**

- a) En utilisant un seul arbre de décision
- b) En choisissant un sous-ensemble aléatoire de caractéristiques pour chaque arbre
- c) En normalisant les données avant l'entraînement
- d) En appliquant une régularisation sur les arbres de décision

**31. Quel est le rôle du noyau (kernel) dans un modèle SVM ?**

- a) Augmenter la taille du jeu de données

- b) Effectuer une transformation des données dans un espace de plus grande dimension
- c) Normaliser les données avant l'entraînement
- d) Réduire la dimensionnalité des données

**32. Qu'est-ce que le surajustement (overfitting) ?**

- a) Le modèle généralise bien mais manque de précision
- b) Le modèle apprend trop bien les données d'entraînement et ne généralise pas bien
- c) Le modèle est trop simple
- d) Le modèle ignore les valeurs aberrantes

**33. Quel est le principal risque du suréchantillonnage des données minoritaires ?**

- a) Une perte d'information
- b) Une augmentation du surajustement
- c) Une augmentation du biais
- d) Une réduction de la variance

**34. Quel algorithme est couramment utilisé pour combiner plusieurs modèles faibles ?**

- a) Régression linéaire
- b) Gradient Boosting
- c) K-Means
- d) PCA

**35. Quel algorithme est le plus adapté pour un problème de classification avec une forte séparation non linéaire ?**

- a) Régression linéaire
- b) SVM avec noyau
- c) K-Means
- d) Régression logistique

**36. Quel est l'objectif du Gradient Boosting ?**

- a) Réduire le nombre de dimensions
- b) Combiner plusieurs modèles faibles pour créer un modèle fort
- c) Réduire le bruit dans les données
- d) Trouver les valeurs aberrantes

**37. Quelle est la fonction utilisée dans une régression logistique pour transformer les scores en probabilités ?**

- a) Fonction tanh
- b) Fonction sigmoïde
- c) Fonction Softmax
- d) Fonction ReLU

**38. Pourquoi la validation croisée est-elle importante ?**

- a) Pour détecter les valeurs aberrantes
- b) Pour évaluer la robustesse du modèle
- c) Pour améliorer la précision du modèle
- d) Pour réduire la complexité du modèle

**39. Quelle est la principale différence entre train-test split et validation croisée ?**

- a) Train-test split est plus précis
- b) Validation croisée utilise plusieurs partitions pour entraîner et tester
- c) Train-test split ne nécessite pas de normalisation
- d) Il n'y a pas de différence

**40. Quel est l'objectif principal de l'apprentissage non supervisé ?**

- a) Prédire une sortie à partir d'une entrée
- b) Trouver des structures cachées dans les données
- c) Maximiser la précision du modèle
- d) Réduire le bruit dans les données

**41. Quel algorithme est couramment utilisé pour le clustering ?**

- a) SVM
- b) K-Means
- c) Régression linéaire
- d) Random Forest

**42. Quel algorithme de clustering peut identifier des formes de clusters non sphériques ?**

- a) K-Means
- b) DBSCAN
- c) Régression logistique
- d) PCA

**43. Que signifie le terme "nombre de clusters K" dans K-Means ?**

- a) Le nombre de dimensions des données
- b) Le nombre de points de données
- c) Le nombre de groupes à identifier
- d) Le nombre d'itérations

**44. Quel algorithme réduit la dimensionnalité des données en conservant un maximum de variance ?**

- a) K-Means
- b) PCA
- c) DBSCAN
- d) Random Forest

**45. Quel est l'inconvénient majeur de K-Means ?**

- a) Il nécessite de spécifier le nombre de clusters à l'avance
- b) Il est insensible aux valeurs aberrantes
- c) Il ne fonctionne qu'avec des variables catégorielles
- d) Il ne fonctionne qu'avec des données linéaires

**46. Pourquoi applique-t-on PCA avant le clustering ?**

- a) Pour améliorer la classification
- b) Pour réduire la complexité du modèle
- c) Pour augmenter la taille des données
- d) Pour détecter les anomalies

**47. Quelle est la principale différence entre clustering hiérarchique et K-Means ?**

- a) Clustering hiérarchique est plus rapide
- b) Clustering hiérarchique ne nécessite pas de spécifier le nombre de clusters
- c) K-Means est supervisé
- d) Il n'y a pas de différence

**48. Quel algorithme peut être utilisé pour détecter des anomalies dans un jeu de données ?**

- a) K-Means
- b) Isolation Forest
- c) Random Forest
- d) Naïve Bayes

**49. Quel type de clustering ne nécessite pas de spécifier le nombre de clusters ?**

- a) K-Means
- b) DBSCAN
- c) Régression logistique
- d) SVM

**50. Quelles sont les composantes principales dans PCA ?**

- a) Des combinaisons linéaires des variables originales qui maximisent la variance
- b) Des clusters de données similaires
- c) Des coefficients de corrélation
- d) Des probabilités conditionnelles

**51. Quelle métrique est couramment utilisée pour évaluer la qualité d'un clustering ?**

- a) Accuracy
- b) Silhouette Score
- c)  $R^2$
- d) MSE

**52. Quelle est la principale caractéristique des méthodes basées sur les distances comme K-Means ?**

- a) Elles minimisent la distance intra-cluster
- b) Elles maximisent la variance
- c) Elles sont supervisées
- d) Elles ne nécessitent pas de normalisation

**53. Qu'est-ce que l'apprentissage semi-supervisé ?**

- a) Un apprentissage utilisant uniquement des données étiquetées
- b) Un apprentissage utilisant à la fois des données étiquetées et non étiquetées
- c) Un apprentissage nécessitant une supervision humaine constante
- d) Un apprentissage utilisant uniquement des données non étiquetées

**54. Quel algorithme peut être utilisé en apprentissage semi-supervisé ?**

- a) Self-training
- b) Label Propagation
- c) K-Means
- d) Régression logistique

**55. Quel est l'un des principaux défis de l'apprentissage semi-supervisé ?**

- a) Il est trop rapide à entraîner
- b) Il nécessite un grand nombre de données étiquetées
- c) Il peut propager des erreurs si les pseudo-étiquettes sont incorrectes
- d) Il ne peut pas être utilisé pour des tâches de classification

**56. Qu'est-ce que l'apprentissage par renforcement ?**

- a) Un modèle qui apprend à partir d'un ensemble de données fixes
- b) Un apprentissage basé sur un agent interagissant avec un environnement pour maximiser une récompense
- c) Une approche nécessitant uniquement des données étiquetées
- d) Un apprentissage utilisant uniquement des méthodes supervisées

**57. Quelle est la différence entre exploration et exploitation en apprentissage par renforcement ?**

- a) Exploration consiste à utiliser les meilleures actions connues
- b) Exploration consiste à tester de nouvelles actions, exploitation utilise les actions connues
- c) Exploitation consiste à choisir des actions aléatoires
- d) Il n'y a pas de différence

**58. Quel algorithme est couramment utilisé en apprentissage par renforcement ?**

- a) K-Means
- b) Q-Learning
- c) Régression logistique
- d) PCA

**59. Quel est le rôle d'un agent dans l'apprentissage par renforcement ?**

- a) Observer l'environnement sans agir
- b) Observer l'environnement et prendre des actions pour maximiser une récompense
- c) Classer automatiquement les types d'attaques
- d) Réaliser un clustering des données

**60. Quelle est la principale caractéristique des méthodes basées sur les politiques (policy-based methods) ?**

- a) Elles apprennent directement une fonction qui mappe les états aux actions
- b) Elles utilisent uniquement une table pour stocker les récompenses
- c) Elles apprennent directement une fonction qui mappe les états aux actions
- d) Elles ne prennent pas en compte l'environnement

**61. Quelle est la différence entre apprentissage par renforcement avec modèle (model-based) et sans modèle (model-free) ?**

- a) Les méthodes avec modèle utilisent une représentation de l'environnement
- b) Les méthodes sans modèle sont toujours meilleures
- c) Les méthodes avec modèle ne nécessitent pas d'interactions avec l'environnement
- d) Il n'y a pas de différence

**62. Quel est l'objectif de l'algorithme Deep Q-Network (DQN) ?**

- a) Utiliser un réseau de neurones pour compresser les images
- b) Utiliser un réseau de neurones pour approximer la fonction de valeur d'un agent
- c) Réaliser du clustering non supervisé



- d) Réduire la variance des données

**63. Quel domaine utilise couramment l'apprentissage par renforcement ?**

- a) Classification des emails
- b) Jeux vidéo et intelligence artificielle
- c) Analyse en composantes principales
- d) Segmentation d'images

**64. Quelle est la principale caractéristique des méthodes policy-based en apprentissage par renforcement ?**

- a) Elles apprennent directement une fonction qui mappe les états aux actions
- b) Elles optimisent directement les actions à prendre
- c) Elles nécessitent des données supervisées
- d) Elles ne prennent pas en compte l'environnement

**65. Qu'est-ce que le problème du crédit assigné (credit assignment problem) en apprentissage par renforcement ?**

- a) Déterminer quelle action a conduit à une récompense donnée
- b) Évaluer la complexité computationnelle d'un algorithme
- c) Assigner un coût d'entraînement à chaque itération
- d) Trouver le meilleur algorithme de classification

**66. Quelle approche en apprentissage semi-supervisé vise à améliorer la robustesse du modèle ?**

- a) Semi-supervised Noise Injection
- b) Dropout
- c) Consistency Regularization
- d) Data Augmentation

**67. Quel est l'avantage principal de l'apprentissage semi-supervisé par rapport à l'apprentissage supervisé ?**

- a) Il nécessite une grande quantité de données étiquetées
- b) Il permet de tirer parti d'un grand nombre de données non étiquetées
- c) Il est plus rapide
- d) Il ne nécessite aucune donnée étiquetée

**68. Quelle est la principale différence entre apprentissage par renforcement model-based et model-free ?**

- a) Model-based utilise une représentation de l'environnement
- b) Model-free est toujours mieux
- c) Model-based ne nécessite pas d'interactions
- d) Il n'y a pas de différence

**69. Quel est l'objectif principal de l'algorithme Self-training ?**

- a) Le modèle apprend uniquement à partir des données non étiquetées
- b) Un modèle initialement entraîné sur des données étiquetées prédit les labels des données non étiquetées
- c) Il génère aléatoirement des étiquettes
- d) Il ne nécessite pas de supervision humaine

**70. Quel est le principe de l'algorithme Q-Learning ?**

- a) Identifier des clusters dans les données
- b) Apprendre une politique optimale en maximisant la récompense cumulée
- c) Réaliser une classification supervisée
- d) Compresser des images

**71. Quel est l'avantage principal de l'apprentissage par renforcement dans les jeux vidéo ?**

- a) Il est plus rapide que les autres algorithmes
- b) Il peut apprendre des stratégies complexes en interagissant avec l'environnement
- c) Il nécessite moins de données
- d) Il ne nécessite pas de récompense

**72. Quelle est la différence entre exploration et exploitation ?**

- a) Exploration teste de nouvelles actions, exploitation utilise les actions connues
- b) Exploration maximise la récompense
- c) Exploitation teste des actions aléatoires
- d) Il n'y a pas de différence

**73. Quel est l'avantage principal d'un modèle de Random Forest ?**

- a) Il est plus rapide que les arbres individuels
- b) Il est moins sujet au surajustement
- c) Il fonctionne uniquement pour la classification
- d) Il réduit la dimensionnalité des données

**74. Quelle technique est utilisée pour combiner plusieurs modèles faibles ?**

- a) Réduction de dimension
- b) Bagging ou Boosting
- c) Clustering
- d) Normalisation

**75. Quel algorithme est couramment utilisé pour détecter des anomalies dans les réseaux ?**

- a) Régression linéaire
- b) Isolation Forest
- c) K-Means
- d) Naïve Bayes

**76. Quel domaine utilise couramment l'apprentissage non supervisé ?**

- a) Classification des emails
- b) Cybersécurité
- c) Régression linéaire
- d) Jeux vidéo

**77. Quelle est la principale différence entre apprentissage supervisé et non supervisé ?**

- a) Supervisé utilise des données étiquetées
- b) Non supervisé cherche des structures cachées dans les données
- c) Supervisé est plus rapide
- d) Il n'y a pas de différence

**78. Quelle est la principale différence entre apprentissage supervisé et semi-supervisé ?**

- a) Semi-supervisé utilise à la fois des données étiquetées et non étiquetées
- b) Supervisé est plus précis
- c) Semi-supervisé est plus rapide
- d) Il n'y a pas de différence

**79. Quel framework est couramment utilisé pour implémenter des algorithmes d'apprentissage par renforcement ?**

- a) Scikit-learn
- b) TensorFlow ou PyTorch
- c) Keras
- d) NumPy

**80. Quelle bibliothèque Python est couramment utilisée pour implémenter des algorithmes de clustering ?**

- a) Scikit-learn
- b) TensorFlow
- c) PyTorch
- d) Pandas